Detección de fraude en transacciones con tarjeta de crédito mediante aprendizaje de máquina

1st Lisbeth Cataño Sepulveda
Departamento de Ingenieria en Sistemas
Universidad de Antioquia UdeA
Medellin, Colombia
lisbeth.catano@udea.edu.co

2nd Kelly Julieth Arango Henao
Departamento de Ingenieria en Sistemas
Universidad de Antioquia UdeA
Medellin, Colombia
kjulieth.arango@udea.edu.co

3rd Maria Bernarda Salazar Sanchez
Departamento de Ingenieria en Sistemas
Universidad de Antioquia UdeA
Medellin, Colombia
bernarda.salazar@udea.edu.co

***Abstract*—Este trabajo presenta el diseño, análisis y simulación de un sistema de detección de fraude en transacciones con tarjeta de crédito mediante técnicas de aprendizaje automático, utilizando la base de datos pública Credit Card Fraud Detection, proporcionada por el Machine Learning Group de la Université Libre de Bruxelles (ULB). Después de realizar una limpieza inicial, el conjunto de datos utilizado contiene 283.726 transacciones, de las cuales 473 corresponden a fraudes. Debido al marcado desbalance entre las clases, se consideran diferentes métricas de evaluación además de la exactitud. En esta primera etapa se presenta la descripción del problema, el análisis exploratorio de los datos, el estado del arte y la aproximación de aprendizaje automático seleccionada para abordar el problema. La evaluación experimental y la comparación de los modelos se desarrollarán en la siguiente etapa del proyecto.**

***Index Terms*—detección de fraude, aprendizaje automático, clases desbalanceadas, clasificación binaria, reducción de dimensionalidad**

I. Introducción

El fraude en las transacciones realizadas con tarjetas de crédito constituye un problema que puede generar pérdidas económicas tanto para los usuarios como para las entidades financieras. Actualmente se realizan miles de transacciones diariamente, por lo que su revisión manual resulta poco práctica y difícil de realizar a gran escala.

Frente a esta situación, el aprendizaje automático se presenta como una alternativa útil, ya que permite analizar grandes volúmenes de transacciones e identificar patrones que pueden ayudar a distinguir entre operaciones legítimas y potencialmente fraudulentas, sin depender exclusivamente de reglas definidas manualmente. El problema se plantea como una tarea de clasificación binaria supervisada, en la que cada transacción pertenece a una de dos clases: legítima o fraudulenta.

Uno de los principales retos al abordar este problema es el marcado desbalance entre las clases. La gran mayoría de las transacciones son legítimas y solo una proporción muy pequeña corresponde a operaciones fraudulentas. En este contexto, un modelo puede presentar una alta Accuracy general y, al mismo tiempo, tener un bajo desempeño en la detección de los casos de fraude, que constituyen la clase de mayor interés para el problema. Por esta razón, además de Accuracy, se consideran métricas como Precision, Recall, F1-score y ROC-AUC.

En este proyecto se aborda la detección de fraude mediante aprendizaje automático utilizando el conjunto de datos público Credit Card Fraud Detection, publicado por el Machine Learning Group de la Université Libre de Bruxelles (ULB) [1]. En esta primera etapa se realiza la caracterización del conjunto de datos, el análisis exploratorio, la revisión del estado del arte y la definición de la aproximación de aprendizaje. Estas actividades establecen la base metodológica para la posterior evaluación y comparación de diferentes modelos.

II. Material y Métodos

A. Conjunto de datos

Para el desarrollo del trabajo se utiliza el conjunto de datos público Credit Card Fraud Detection, publicado por el Machine Learning Group de la Université Libre de Bruxelles (ULB) [1]. El conjunto de datos original contiene 284.807 transacciones, de las cuales 492 corresponden a operaciones fraudulentas.

Como parte del preprocesamiento inicial, se eliminaron 1.081 registros duplicados, obteniendo un conjunto final de 283.726 transacciones. De estas, 283.253 corresponden a transacciones legítimas y 473 a transacciones fraudulentas, lo que representa aproximadamente el 99,83% y el 0,17% respectivamente, evidenciando un fuerte desbalance entre las clases.

TABLE I
Resumen del conjunto de datos

Característica	Valor
Número de instancias	283.726 (tras eliminar 1.081 duplicados)
Variables de entrada	30 (Time, V1-V28, Amount)
Variable objetivo	Class (Legítima / Fraudulenta)
Distribución de clases	283.253 Legítima (99,83%) / 473 Fraudulenta (0,17%)
Datos faltantes	0
Tipo de datos	Numérico (V1-V28 ya transformadas con PCA)

En cuanto a las variables utilizadas, la base de datos contiene 31 columnas: 30 variables de entrada (Time, V1 a V28 y Amount) y una variable objetivo (Class). La variable Class toma el valor 0 para transacciones legítimas y 1 para transacciones fraudulentas. La variable Time representa el

tiempo transcurrido desde la primera transacción, y Amount corresponde al valor de la transacción. No se identificaron valores faltantes en ninguna variable.

TABLE II
VARIABLES DE LA BASE DE DATOS

Var.	Descripción	Tipo	Preproc.
Time	Segundos desde la primera transacción	Numérica	Estandarización
V1-V28	Componentes PCA anonimizados	Numérica	Ninguno
Amount	Monto de la transacción	Numérica	Estandarización
Class	0 = Legítima, 1 = Fraudulenta	Binaria	Ninguno

Las variables V1 a V28 corresponden a componentes obtenidos mediante un proceso de Análisis de Componentes Principales (PCA) aplicado por los autores originales del conjunto de datos para anonimizar la información [1]. Esta particularidad tiene implicaciones importantes para las siguientes etapas del proyecto. En primer lugar, dado que estas variables ya fueron transformadas y escaladas implícitamente por el PCA original, una segunda estandarización sobre ellas puede ser innecesaria, o incluso contraproducente para algunos modelos. En segundo lugar, la interpretabilidad de la importancia de cada variable es limitada, ya que no representan directamente una característica original de la transacción. En tercer lugar, no es posible aplicar PCA nuevamente de forma directa sobre estas variables, ya que equivaldría a realizar un PCA sobre un PCA. Por esta razón, en la siguiente etapa del proyecto (Entregable II) se definirá una estrategia específica para la fase de reducción de dimensión que tenga en cuenta esta particularidad, considerando únicamente Time y Amount como candidatas a transformación adicional.

B. Paradigma de aprendizaje

El problema corresponde al paradigma de aprendizaje supervisado, debido a que el conjunto de datos contiene una variable objetivo conocida (Class) para cada transacción. El objetivo es utilizar las variables de entrada Time, V1 a V28 y Amount para aprender una relación entre las características de las transacciones y su respectiva clase, y utilizar posteriormente dicho modelo para clasificar nuevas transacciones como legítimas o fraudulentas.

Dado el fuerte desbalance de clases descrito en la Tabla I, la métrica principal para la evaluación de los modelos será el área bajo la curva de Precision-Recall (AUC-PR), en lugar del AUC-ROC, ya que este último puede resultar artificialmente alto bajo un desbalance tan extremo. Esta decisión, junto con la estrategia de muestreo a utilizar, se detallará en el Entregable II.

C. Estado del arte

La detección de fraude en transacciones con tarjetas de crédito ha sido abordada mediante diferentes técnicas de aprendizaje automático, principalmente debido al fuerte desbalance entre las transacciones legítimas y fraudulentas. A continuación se describen cuatro trabajos relevantes y su aporte específico al presente proyecto.

Du et al. [2] proponen el método AE-XGB-SMOTE-CGAN, que combina un autoencoder, XGBoost y Conditional GAN para abordar el desbalance de clases, alcanzando un MCC de 0,8845. Este trabajo es relevante porque utiliza la métrica MCC, apropiada para el fuerte desbalance de nuestro problema, y evidencia que las técnicas de generación sintética como SMOTE pueden combinarse con otras estrategias para mejorar la detección de la clase minoritaria.

El Coeficiente de Correlación de Matthews (MCC) se define como:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \tag{1}$$

donde TP, TN, FP y FN corresponden a los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, respectivamente. Esta métrica resulta especialmente adecuada en problemas con fuerte desbalance de clases, como el presente caso, ya que considera las cuatro categorías de la matriz de confusión de forma balanceada.

Carcillo et al. [3] presentan SCARFF, un *framework* de detección de fraude en flujos de transacciones basado en Kafka, Spark y Cassandra. A diferencia de los demás trabajos citados, no utiliza el conjunto de datos de 284.807 transacciones empleado en este proyecto, sino un flujo de datos industrial de mayor escala. Su aporte principal para este trabajo es metodológico: evidencia la importancia de considerar el desbalance de clases y los cambios de comportamiento en escenarios de detección de fraude.

Ileberi et al. [4] utilizan un Algoritmo Genético para la selección de características sobre el mismo conjunto de datos de 284.807 transacciones, obteniendo con Random Forest una Accuracy de 99,98% y una Precision de 95,34%. Este trabajo es particularmente relevante porque plantea una estrategia de reducción de variables aplicable a nuestro problema, a diferencia del PCA tradicional, dado que las variables V1-V28 ya son componentes de PCA.

Albalawi y Dardouri [5] comparan modelos tradicionales y de aprendizaje profundo sobre el mismo conjunto de datos, utilizando SMOTE y validación cruzada estratificada; su mejor modelo tradicional (XGBoost) obtuvo un F1-score de 93,30% y un ROC-AUC de 99,98%. Este trabajo aporta una referencia directa de desempeño para comparar los modelos que se entrenarán en el presente proyecto, al utilizar exactamente el mismo conjunto de datos.

TABLE III
RESUMEN COMPARATIVO DEL ESTADO DEL ARTE

Ref.	Técnica	Métrica	Aporte al proyecto
[2]	AE-XGB-SMOTE-CGAN	MCC = 0,8845	Uso de MCC para desbalance extremo
[3]	Framework streaming (Kafka/Spark)	Precision-recall	Importancia del desbalance y cambio de comportamiento
[4]	GA + Random Forest	Acc. 99,98%, Prec. 95,34%	Alternativa de reducción de variables sin PCA
[5]	XGBoost + SMOTE	F1 93,30%, ROC-AUC 99,98%	Referencia directa de desempeño (mismo dataset)

En conjunto, estos trabajos confirman que el desbalance de clases es el principal reto del problema abordado, y que estrategias como SMOTE, la generación sintética y la selección de características son las más utilizadas. Dado que en nuestro caso las variables ya corresponden a componentes de PCA, la reducción de dimensión del presente proyecto se abordará considerando esta particularidad, en lugar de aplicar PCA de forma directa como en los trabajos citados.

REFERENCES

[1] Kaggle, "Credit Card Fraud Detection," Machine Learning Group - ULB. [Online]. Available: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

[2] H. Du, L. Lv, H. Wang, and A. Guo, "A novel method for detecting credit card fraud problems," *PLoS ONE*, vol. 19, no. 3, e0294537, 2024.

[3] F. Carcillo, A. Dal Pozzolo, Y.-A. Le Borgne, O. Caelen, Y. Mazzer, and G. Bontempi, "Scarff: a scalable framework for streaming credit card fraud detection with Spark," *Information Fusion*, vol. 41, pp. 182-194, 2018.

[4] E. Ileberi, Y. Sun, and Z. Wang, "A machine learning based credit card fraud detection using the GA algorithm for feature selection," *Journal of Big Data*, vol. 9, art. 24, 2022.

[5] T. Albalawi and S. Dardouri, "Enhancing credit card fraud detection using traditional and deep learning models with class imbalance mitigation," *Frontiers in Artificial Intelligence*, vol. 8, art. 1643292, 2025.