

Deteccion de fraude en transacciones con tarjeta de credito mediante aprendizaje de maquina

[Nombre 1], [Nombre 2], [Nombre 3] Departamento de Ingenieria de Sistemas, Universidad de Antioquia, Colombia [correos]

Resumen- Este trabajo presenta el diseno, analisis y simulacion de un sistema de prediccion de fraude en transacciones con tarjeta de credito basado en tecnicas de aprendizaje de maquina, usando la base de datos publica de la ULB (283.726 transacciones tras limpieza, 473 fraudes, 0,167 %). Se describe el problema, se revisa el estado del arte, se especifican los modelos y la metodologia de validacion, y se reportan los resultados y conclusiones. [Completar al finalizar el Entregable II.]

Palabras clave- deteccion de fraude, aprendizaje de maquina, clases desbalanceadas, reduccion de dimension.

I. ORIENTACION GENERAL

El equipo selecciono el problema de deteccion de fraude con tarjetas de credito, abordable con las tecnicas vistas en el curso. La base de datos es "Credit Card Fraud Detection", publicada por el Machine Learning Group de la ULB en Kaggle. [Confirmar con el docente que ningun otro equipo desarrolla este dataset.]

El repositorio de GitHub aloja este reporte en PDF y al menos un notebook que reproduce los resultados; el README indica como interactuar con el repositorio. [Insertar enlace al repositorio.]

II. ENTREGABLE I

1. Descripcion del problema

A. Contexto del problema y utilidad del ML

El fraude con tarjetas de credito genera perdidas economicas a bancos y clientes, y las reglas manuales no escalan al volumen actual de transacciones. Un modelo de ML puede asignar a cada transaccion una probabilidad de fraude en tiempo casi real y priorizar las alertas que revisan los analistas, con el objetivo de recuperar la mayor cantidad de fraudes posible sin generar demasiadas falsas alarmas.

B. Composicion de la base de datos

El conjunto original contiene 284.807 transacciones realizadas con tarjetas de credito por titulares europeos en septiembre de 2013, de las cuales 492 son fraude. Se identificaron 1.081 filas duplicadas, las cuales fueron eliminadas; tras la limpieza el conjunto de trabajo queda con 283.726 transacciones, de las cuales 473 son fraude (0,167 %) y 283.253 son legitimas (99,833 %), lo que confirma un desbalance de clases extremo. No se encontraron datos faltantes, por lo que no fue necesaria ninguna estrategia de imputacion.

Todas las variables de entrada son numericas: V1 a V28 son componentes principales obtenidos mediante PCA por razones de confidencialidad, mientras que Time (segundos desde la primera transaccion) y Amount (monto) no fueron transformadas. Al ser ya componentes de PCA, V1-V28 no tienen una interpretacion directa, y esto se retoma en la discusion de la seccion de reduccion de dimension.

Var.	Descripcion	Tipo	Preproc.
Time	Segundos desde la primera transaccion	Numerica	Estandarizacion
V1-V28	Componentes PCA anonimizados	Numerica	Ninguno
Amount	Monto de la transaccion	Numerica	Estandarizacion
Class	0 = legitima, 1 = fraude	Binaria	Ninguno

TABLA I. Variables de la base de datos.

El analisis exploratorio mostro ademas dos patrones relevantes. Primero, el monto de los fraudes tiende a ser menor que el de las transacciones legitimas: la mediana de Amount en fraude es 9,82 frente a 22,00 en transacciones normales, y el fraude mas alto registrado es de 2.125,87 frente a un maximo de 25.691,16 en las legitimas. Segundo, la proporcion de fraudes es notablemente mayor durante las horas de madrugada, cuando el volumen de transacciones legitimas cae, lo que sugiere que variables derivadas de Time podrian aportar poder predictivo.

El analisis de correlacion individual muestra que las variables mas asociadas con Class son V17, V14, V12, V10 y V16, con coeficientes de correlacion (en valor absoluto) entre 0,187 y 0,313; el resto de variables presenta asociaciones mas debiles.

C. Paradigma de aprendizaje

Aprendizaje supervisado, en su configuracion de clasificacion binaria con clases fuertemente desbalanceadas. Se justifica porque la base de datos incluye etiquetas confirmadas de fraude y el objetivo es predecir Class para transacciones nuevas.

2. Estado del arte

Se revisaron al menos cuatro trabajos que abordan el mismo problema de aprendizaje, incluyendo, en lo posible, la misma base de datos [1]-[4].

Ref.	Paradigma	Tecnicas	Validacion	Metricas	Resultados
[1] Frontiers in AI, 2025	[compl.]	[compl.]	[compl.]	[compl.]	[compl.]
[2] Dornadula et al., 2019	[compl.]	[compl.]	[compl.]	[compl.]	[compl.]
[3] Carcillo et al., 2018	[compl.]	[compl.]	[compl.]	[compl.]	[compl.]
[4] [buscar]	[compl.]	[compl.]	[compl.]	[compl.]	[compl.]

TABLA II. Comparacion de trabajos previos.

[Pendiente] Completar la tabla con paradigma, tecnicas, validacion, metricas y resultados de cada articulo, y redactar el parrafo comparativo (max. 1 pagina).

III. ENTREGABLE II

Esta seccion incorpora los apartados del Entregable I con las mejoras derivadas de la realimentacion del docente. [Pendiente.]

1. Entrenamiento y evaluacion de modelos

A. Metodologia de validacion

[Pendiente] Validacion cruzada estratificada sobre entrenamiento y un test estratificado separado desde el inicio, con la distribucion real de clases. El escalado y las tecnicas de sub/sobre muestreo (p. ej. SMOTE) se ajustan solo con los datos de entrenamiento de cada fold, para evitar fuga de datos.

B. Modelos e hiperparametros

Modelo	Hiperparam.	Malla
Regresion logistica	C; penalizacion	[compl.]
KNN	k; pesos	[compl.]
Ensamble de arboles	n_estim.; profund.	[compl.]
Red neuronal (MLP)	capas; alpha	[compl.]
SVM	kernel; C; gamma	[compl.]

TABLA III. Hiperparametros por modelo.

C. Metricas de desempeno

Dado el desbalance de clases (0,167 % de fraude), la exactitud no es informativa: un modelo que prediga siempre "legitima" alcanzaria 99,833 % sin detectar ningun fraude. Se usaran precision, recall, F1 y AUPRC como metricas principales. [Justificar y, si aplica, incluir definicion matematica de AUPRC.]

Resultados del entrenamiento

[Pendiente] Tablas y figuras con caption y ejes nombrados; resultados de entrenamiento, validacion y test con intervalos de confianza.

2. Reduccion de dimension

A. Analisis individual de variables

Del analisis de correlacion realizado en la seccion II.1.B, las variables V17, V14, V12, V10 y V16 presentan la mayor asociacion con Class. [Completar con indice de discriminacion y candidatas a eliminar.]

B. PCA

[Pendiente] Criterio para el numero de componentes, reevaluacion de los 2 mejores modelos, tabla de reduccion y desempeno.

C. UMAP

[Pendiente] Igual que PCA. Incluir discusion final, considerando que V1-V28 ya son componentes de PCA.

3. Evaluacion

- Objetivos de cada seccion alcanzados.
- Reporte de maximo 10 paginas.
- Repositorio GitHub ordenado y reproducible.

- Video de sustentacion de 10 minutos.

REFERENCIAS

- [1] Kaggle, "Credit Card Fraud Detection," Machine Learning Group - ULB. [Online]. Available: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
- [2] A. Dal Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, "Calibrating Probability with Undersampling for Unbalanced Classification," in Proc. IEEE Symp. Computational Intelligence and Data Mining (CIDM), 2015.
- [3] "Enhancing credit card fraud detection using traditional and deep learning models with class imbalance mitigation," Frontiers in Artificial Intelligence, 2025. [completar autores].
- [4] V. N. Dornadula et al., "Credit Card Fraud Detection using Machine Learning Algorithms," Procedia Computer Science, vol. 165, pp. 631-641, 2019.
- [5] F. Carcillo et al., "Scarff: a scalable framework for streaming credit card fraud detection with Spark," Information Fusion, vol. 41, pp. 182-194, 2018.